

🚀 부도 예측 모델 1차 모델링 및 심층 SHAP 분석 결과

이전의 기초 분석을 넘어, 이번에는 부도 예측 모델(LightGBM)이 판단 기준으로 삼은 핵심 변수를 50개까지 확장하여 살펴보고, 특히 중요도가 높게 나타난 업종(STD_INDS_CFC)에 대해 한글 업종명과 매핑하여 심층 분석을 진행했습니다.

📊 모델 성능 지표 (Valid 데이터 검증, 복습)

[!TIP]

부도 예측 모델(N=12M) 결과 요약

- ROC AUC: 0.9011 (매우 우수한 변별력)
- Recall(재현율): 0.65
- Precision(정밀도): 0.15

💡 주요 50대 핵심 변수 중요도 (Top 50 SHAP)

부도 확률에 영향을 미치는 상위 50개 변수에 대한 요약 차트입니다.
(가로축은 SHAP 값으로, 양수(+)는 부도 확률 증가를, 음수(-)는 부도 확률 감소를 의미합니다. 붉은색일수록 해당 변수의 실제 값이 큼니다.)

SHAP Top 50 Feature Importance

🔗 Top 50 주요 시사점

- 재무 데이터의 중요성: JEMU_123000(자본총계), JEMU_191310(차입금 의존도), JEMU_118900(매출채권회전율) 등 다양한 재무 비율과 절대 수치가 상위권에 대거 포진해 있습니다.
- 거시경제 지표 뚜렷한 영향: 환율(EUR_KRW_vol_m), 코스피 지수(KOSPI_log_ret), 물가상승률(CPI_core_yoy), 대출 금리 관련 지수 등 거시경제 지표가 20위 권 밖에서도 꾸준히 예측 모델의 정확도를 끌어올리는 보조 역할을 하고 있습니다!
- 업력과 규모: BUSINESS_AGE(업력)와 AA10_PERS_CNT(종업원 수) 역시 기업의 안정성을 가능하게 하는 주요 지표로 작용합니다.

🏢 업종(STD_INDS_CFC) 심층 분석: 어떤 업종이 가장 위험할까?

상위 주요 피쳐 중 하나인 업종코드(STD_INDS_CFC)에 대해 토크스 연계표를 활용하여 한글 업종명을 결합하고, 모델이 "어떤 업종을 부도에 더 취약하다"고 판단했는지 심층 분석을 진행했습니다. (분석의 신뢰도를 위해 샘플 내 50건 이상 존재하는 업종만 필터링했습니다.)

⚠️ 부도 위험이 가장 높은 상위 10개 업종 (위험도 순)

주로 건설업, 부동산 관련 서비스, 그리고 경기 민감 인력/행사 대행업이 최상위권에 랭크되었습니다. 이는 최근의 경제 상황 및 고금리 환경의 직격탄을 맞는 산업군과 정확히 일치합니다!

업종코드 부도 위험도 (평균 SHAP)데이터 건수 한글 업종명 (표준산업/토크스명)

91121	+0.314	97	골프장 운영업
41220	+0.281	245	기타 전문 공사업 (건설업)
75992	+0.279	93	전시, 컨벤션 및 행사 대행업
46741	+0.255	240	방직용 섬유 및 실 도매업
71310	+0.254	162	광고 대행업
41112	+0.251	184	아파트 건설업
72129	+0.246	170	기타 엔지니어링 서비스업
72121	+0.234	165	건물 및 토목 엔지니어링 서비스업
41110	+0.231	102	단독 및 연립 주택 건설업
72919	+0.226	80	기타 기술 시험, 검사 및 분석업

🟢 부도 위험이 가장 낮은 상위 10개 업종 (안전도 순)

반면 식음료 제조, 사료 등 필수 소비재 기반의 기초 산업은 상대적으로 부도 확률을 크게 낮추는 (안전한) 요인으로 작용했습니다.

업종코드 부도 위험도 (평균 SHAP)데이터 건수 한글 업종명 (표준산업/토크스명)

10897	-0.399	102	건강 기능식품 제조업
10709	-0.359	51	기타 식사용 가공처리 조리식품 제조업
10902	-0.352	103	배합사료 제조업
10903	-0.347	56	단미사료 및 기타 사료 제조업
10899	-0.322	202	그 외 기타 식료품 제조업
10611	-0.308	53	곡물 도정업 (분류 등)
10839	-0.294	57	기타 식품 첨가물 제조업
14112	-0.292	58	여자용 겔옷 제조업
10892	-0.285	62	차류 가공업
11209	-0.283	66	기타 비알코올 음료 제조업

🎯 모델 최적화: VIF 다이어트 및 Z-Score 신용등급화 평가

실무 적용성을 극대화하기 위해, 다중공선성(VIF) 다이어트를 통해 중복된 정보를 가진 변수들을 대폭 제거하고 핵심 변수만 남기는 경량화 작업을 진행했습니다. 또한 확률을 Z-Score 분포로 정규화하여 실무에서 즉시 활용 가능한 5단계 신용(부도) 리스크 등급을 도출했습니다.

🍽️ VIF 피쳐 다이어트 (Feature Diet)

[!NOTE]

기존 230개에 달하던 방대한 변수들 중 상관성이 높은 중복 재무/거시 지표들을 엄격하게 제거(VIF < 10)했습니다.

- 최종 생존 변수: 230개 $\Rightarrow$ 80개 핵심 변수로 압축 완료!
- Lean 모델 성능: ROC AUC 0.8806 (230개 풀모델 0.9011 대비 성능 98% 보존 성공)

변수 개수를 거의 3분의 1 수준으로 다이어트했음에도 불구하고 성능 하락을 방어함으로써, 운영 환경에서 훨씬 빠르고 안정적으로 동작하는 **경량화 모델(Lean Model)**이 완성되었습니다.

2 Z-Score 기반 리스크 5등급표 (위험도 구간화)

예측된 부도 확률의 로그-오즈(Log-odds)를 Z-Score(표준정규분포)로 변환한 후, 이를 **5개의 리스크 등급(Risk Grade)**으로 나누었습니다.

[!TIP]

실무적으로 기업 심사를 할 때 "이 기업의 등급은 5등급(가장 위험)입니다."와 같이 즉각적인 커뮤니케이션이 가능해집니다.

Risk Grade (1=안전, 5=위험)	평가 대상 건수	실제 부도 발생 건	구간별 실제 부도율	누적 부도	탐지율
Grade 1 (가장 안전)	483,245	791	0.16%		3.05%
Grade 2	165,653	1,667	1.01%		9.48%
Grade 3	63,746	1,613	2.53%		15.70%
Grade 4	89,243	7,684	8.61%		45.34%
Grade 5 (가장 위험)	88,866	14,171	15.95%		100.0%

🔍 Z-Score 등급표 핵심 인사이트

- 완벽한 리스크 변별력: 안전한 Grade 1(0.16%)에서 가장 위험한 Grade 5(15.95%)로 갈수록 부도율이 단 한 번의 역전 없이 급격하게 치솟는 매우 이상적인 계단형 구조를 보입니다.
- 고위험군 타겟팅: 가장 위험한 **Grade 4와 Grade 5**, 이 두 구간에 전체 부도 건수의 약 **85% 이상이 몰려 있습니다**.
- 실무 활용 방안: 은행이나 평가기관은 **Grade 4, 5**에 배정된 업체를 집중적으로 정밀 심사(Reject 또는 한도 축소)하고, **Grade 1, 2** 업체는 자동 대출(Auto-Approval) 프로세스를 신속히 통과시키는 전략을 취할 수 있습니다.

3 최적 판단 기준선 (Threshold Tuning)

가장 균형 잡힌 모델 판별 임계값을 산출했습니다.

- 의미: 모델이 뱉어낸 확률이 약 5%를 넘어가면 "위험 징후"가 있는 것으로 간주할 때, 정상 기업을 오판하는 비용과 부도 기업을 놓치는 비용 사이의 수학적 타협점이 가장 이상적입니다. (이 수치는 Z-Score Grade 4의 컷오프 부근과 절묘하게 일치합니다!)

🚀 Walkthrough v2: 실무 수용성 및 비즈니스 정합성 검증

이전 Walkthrough에서 산출된 모델의 통계적 성능(AUC 0.90)과 VIF 다이어트 결과에 이어, **실무 환경에서 실제로 쓸 수 있는가?**에 대한 해답을 찾기 위해 심층 분석을 추가로 진행했습니다. 특히, "미탐(부도 기업을 놓침) 비용이 오탐 비용보다 압도적으로 높다"는 현업의 피드백을 반영하여 **비용 기반 임계값 최적화(Cost-Optimal Threshold)**를 수행하고, 시간에 따른 모델 성능의 안정성, 결측치가 모델에 미치는 영향을 체계적으로 검증했습니다.

📊 비용 기반 최적 임계값 (Cost-Optimal Threshold)

기본적인 모델 판별 기준은 Precision(정밀도)과 Recall(재현율) 간의 트레이드오프가 존재합니다. 기존(Threshold 0.0496)에는 정상 기업 오판 비용과 부도 기업 누락 비용을 동일하게 보았기 때문에, 재현율은 높지만 실무 적용 시 정밀도가 낮아 현업 부서의 오경보 피로도가 높아질 우려가 있었습니다.

[!IMPORTANT]

비즈니스 비용 함수 적용 (부도 미탐 비용 = 오탐 비용의 20배)

현업의 조언을 반영하여 부도를 탐지하지 못했을 때 발생하는 총당금 적립 및 채권보전 비용(FN Cost)을, 정상 기업을 오판하여 대출 심사를 강화하는 행정 피로도(FP Cost)의 **20배**로 설정했습니다.

Cost Optimization by Threshold

최적화 산출 결과:

- Best F1 Threshold:** 0.7399 (Precision: 20.4%, Recall: 42.3%) - 가장 이상적인 통계적 타협점이나 미탐(미탐지)이 많이 발생함.
- 최소 비용 임계값 (Min Cost Threshold):** 0.2698 (Precision: 12.7%, Recall: 82.6%)

🔍 실무 적용 시사점:

비용을 최소화하는 새로운 컷오프(0.2698)를 적용하면 **실제 부도 건수의 82.6%**을 성공적으로 탐지해 내면서도, 오경보를 감당 가능한 **실무적 수준(약 12.7% 정밀도)**으로 제어할 수 있습니다. 은행권의 평균 부도율이 약 1% 내외임을 감안하면, "모델이 위험하다고 판단한 기업 중 약 13%가 실제 부도"라는 것은 랜덤 대비 **13배 이상의 예측 정확도(Lift)**를 가지는 매우 강력한 성능입니다!

2 시간 기반 교차검증 (Time-Series Cross Validation)

부도 예측 모델은 시간이 지남에 따라 거시 경제 환경이나 시장 변화로 인해 성능이 하락할 위험이 큼니다. 모델이 과거의 특정 시점(단기 데이터)에 과적합되지 않았는지 검증하기 위해 **Rolling Window** 시간 기반 교차검증(2023년 분기별)을 수행했습니다.

예측 적용 (Valid) 기간 ROC AUC

23년 2분기 (23.04 ~ 23.06) 0.9851

23년 3분기 (23.07 ~ 23.09) 0.9542

23년 4분기 (23.10 ~ 23.12) 0.9159

🔍 검증 결과: 미래로 갈수록 불가피한 성능 하락(Degradation)이 나타나지만, **가장 먼 미래 시점(23년 4분기)에서도 AUC가 0.916**으로 예측력이 거의 흔들리지 않고 매우 우수하게 유지되었습니다. 이는 이 모델이 운영 환경에 배포된 후에도 강건(Robust)하게 작동할 것임을 확신하게 합니다.

3 정보 부재(Missing Value)가 미치는 영향 (SHAP 분석)

실무에서 "신용평가 점수가 없는 기업"이나 "사유 정보가 없는 데이터"가 리스크 관점에서 어떤 영향을 미치는지, 혹시 모델이 이를 단순한 기계적 패턴으로 오해하고 있는지 검증했습니다.

🔗 KIS 신용평가 점수 (CG01_KIS_SCORE)

데이터 전처리 단계에서 결측치가 대부분 -1.0(또는 중앙값)으로 대체되었습니다.

- 신용점수가 존재하는 기업의 부도율: 0.88%
 - 신용점수가 없는(결측치) 기업의 부도율: 6.16%
- 📊 모델의 판단: KIS 신용점수가 없는 그룹에 강한 위험(양+)의 SHAP Value)을 부여했습니다. 이는 신용평가 점수가 존재하지 않는 신생, 영세 기업들이 실질적으로 훨씬 부도에 취약하다는 비즈니스 상식과 100% 일치하는 올바른 판단입니다.

🔗 신용불량사유 (CRIF_CRDBD_RSNC)

전처리 과정에서 사유가 없는 경우 -1로 대체되었습니다.

- 사유가 없는 정상 기업(-1) 부도율: 0.90%
 - 신용불량 사유가 등록된 기업 부도율: 13.07%
- 📊 모델의 판단: 사유가 등록된 기업에 압도적으로 높은 부도 위험(SHAP: +1.31)을 부여하여, 특정 정보가 존재할 때 그 정보를 적재적소에 잘 활용하고 있음을 확인했습니다.

[!TIP]

최종 실무 가이드라인 및 결론

본 프로젝트의 부도 예측 모델은 단순히 **AUC 0.90**을 달성한 기계학습 모델을 넘어섰습니다.

'점수 부재'와 같은 결측치 패턴이 내포하는 진짜 현업 리스크를 비즈니스 상식에 맞게 완벽히 포착하였으며, 실무진의 최대 고민인 **"부도 미량 비용 최적화"**를 위해 **최적의 모델 컷오프(0.2698)**를 새롭게 도출했습니다.

향후 은행 운영 환경(Production) 도입 시, Z-Score 리스크 등급표 및 본 Threshold를 기반으로 대출 심사의 "정밀 관리 타겟"을 스크리닝할 것을 강력히 권장합니다.